## 1과목 빅데이터 분석 기획

1. 다음 중 획득된 다양한 정보를 구조화하여 유의미한 정보로 분류하고 일반화시킨 결과물을 무엇이라고 하는가?
① 데이터 ② 정보
③ 지식 ④ 지혜

2. 다음 중 빅데이터의 특징으로 적합하지 않은 것은?
① 규모 ② 다양성
③ 가치 ④ 효율성

3. 다음 중 분석조직 인력들을 현업 부서로 직접 배치해 분석 업무를 수행하는 조직 구조로 가장 적합한 것은 무엇인가?
① 분산 구조 ② 기능 구조
③ 집중 구조 ④ 계층 구조

4. 다음 중 반정형 데이터 유형으로 가장 적합하지 않은 것은 무엇인가?
① 텍스트 문서 ② XML
③ JSON ④ 웹로그

5. 다음 중 개인정보처리자가 정당한 처리 범위 내에서 정보주체의 동의 없이 가명정보를 처리할 수 있는 분야로 올바르지 않은 것은?
① 특정 집단이나 대상 등에 관하여 작성한 수량적인 정보
② 기술의 개발과 실증, 기초연구, 응용 연구
③ 마케팅 등을 위해 특정 개인을 식별할 수 있는 통계
④ 공공의 이익을 위하여 지속적으로 열람할 가치가 있는 기록정보 보존

6. 개인정보의 일부를 삭제하거나 일부 또는 전부를 대체하는 등의 방법으로 추가정보 없이는 특정 개인을 알아볼 수 없도록 처리하는 것은 무엇인가?
① 익명처리 ② 가명처리
③ 총계처리 ④ 범주화

7. 다음에서 설명하는 비식별 조치 방법은 무엇인가?

| 정약용, 35세 → 정씨, 30대 |
|---|

① 익명처리 ② 총계처리
③ 데이터 범주화 ④ 데이터 마스킹

8. 다음이 설명하는 것은 무엇인가?

| 자신에 관한 정보가 언제 누구에게 어느 범위까지 알려지고 또 이용되도록 할 것인지를 그 정보주체가 스스로 결정할 수 있는 권리 |
|---|

① 개인정보 이동권
② 개인정보 열람권
③ 개인정보 삭제권
④ 개인정보 자기 결정권

9. 다음 분석 기획 유형 중 분석의 대상은 인지하고 있으나 방법을 모르는 경우에 적용하는 유형은 무엇인가?
① 최적화 ② 솔루션
③ 통찰 ④ 발견

10. 다음 중 CRIPS-DM 분석 방법론의 절차는 무엇인가?

① 데이터 세트 선택→데이터 전처리→데이터 변환→데이터 마이닝→데이터 마이닝 결과 평가
② 업무 이해→데이터 이해→데이터 준비→모델링→평가→전개
③ 샘플링→탐색→수정→모델링→검증
④ 문제 인식→연구 조사→모델링→평가

## 2과목 빅데이터 탐색

11. 아래와 같은 데이터가 관측이 되었을 때, 비조건부 평균 대치법으로 결측값을 대치할 때, 대치값으로 가장 알맞은 것은? (단, '?'는 결측값이다.)

| 10, ?, 15, 19, 12, 18, ?, ?, 16 |
|---|

① 14 ② 15
③ 16 ④ 17

12. 통계기법을 이용한 데이터 이상값 검출 방법으로 가장 알맞지 않은 것은?
① ESD(Extreme Studentized Deviation)
② 딕슨의 Q검정
③ 그럽스 T-검정
④ 확률밀도함수

13. 다음 중 필터기법의 사례로 가장 알맞지 않은 것은?
① 정보소득(Information Gain)
② 피셔스코어(Fisher Score)
③ RFE(Recursive Feature Elimination)
④ 상관계수(Correlation Coefficient)

14. 다변량의 신호를 통계적으로 독립적인 하부성분으로 분리하여 차원을 축소하는 기법으로 가장 알맞은 것은?
① 독립성분분석 ② 요인분석
③ 다차원 척도법 ④ 주성분 분석

15. 파생변수 생성방법의 예 중 변수결합에 해당하는 것은?
① 12시간을 24시간으로 변환
② 매출액과 방문 횟수로 평균 매출액 추출
③ 고객별 방문 횟수 집계
④ 남/여를 M/F 로 변환

16. 언더 샘플링 기법 중 다수 클래스의 데이터를 토멕 링크 방법으로 제거한 후 Condensed Nearest Neighbor를 이용하여 밀집된 데이터를 제거하는 기법은?
① ENN ② SMOTE
③ OSS ④ ADASYN

17. EDA(Exploratory Data Analysis)의 4가지 주제로 가장 알맞지 않은 것은?
① Resistance
② Residual
③ Graphic Representation
④ Accuracy

18. 다음 중 변수의 속성에 따른 상관관계 분석 방법으로 가장 알맞은 것은?
① 수치적 데이터 - 카이제곱 검정
② 순서적 데이터 - 스피어만 순위상관분석
③ 명목적 데이터 - 스피어만 순위상관분석
④ 명목적 데이터 - 피어슨 상관계수

19. 다음 중 중위수로 가장 알맞은 것은?

| 3, 5, 7, 11 |
|---|

① 4 ② 5
③ 6 ④ 7

20. 박스 플롯의 구성요소 중 자료들의 하위 75%의 위치를 의미하는 것은?
① 제1사분위 ② 제3사분위
③ 최솟값 ④ 최댓값

## 3과목 빅데이터 모델링

21. 다음 중 회귀 분석 시 회귀 모형의 가정사항으로 가장 옳지 않은 것은
① 선형성 ② 상관성
③ 등분산성 ④ 독립성

22. 다음 중 회귀 모형의 검증 체크리스트에 대한 설명 중 가장 옳지 않은 것은?
① 추정된 회귀식은 유의수준 5% 하에서 F-통계량의 p-값이 0.05보다 클 경우 통계적으로 유의하다고 볼 수 있다.
② 회귀계수의 유의성은 해당 계수의 T-통계량을 이용한다.
③ 모형의 설명력은 결정계수를 확인한다.
④ 데이터는 선형성, 독립성, 등분산성, 비상관성, 정상성 가정을 만족시켜야 한다.

23. 게임에서 이길 확률이 3/10, 질 확률이 7/10일 경우 게임에서 이길 승산(Odds)은 얼마인가?
① 3/7 ② 3/10
③ 7/10 ④ 7/3

24. 의사결정나무에서 과대적합을 방지하기 위하여 더 이상 가지가 분리가 일어나지 않고 현재의 마디가 끝마디가 되도록 하는 규칙은 무엇인가?
① 가지치기 ② 정지규칙
③ 분류규칙 ④ 분리기준

25. 다음 중 의사결정나무에서 분류규칙을 선택하기 위하여 사용하는 척도가 아닌 것은 무엇인가?
① 카이제곱 통계량
② 지니 지수
③ 엔트로피 지수
④ 분산

26. 다음 그림의 지니 지수는 얼마인가?

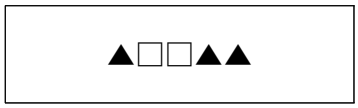

① 2/5 ② 3/5
③ 13/25 ④ 12/25

27. 다음 중 의사결정나무의 알고리즘인 CART에 대한 설명으로 가장 옳지 않은 것은?
① 각 독립변수를 이분화 하는 과정을 반복하여 이진트리 형태를 형성함으로써 분류를 수행하는 방법이다.
② 변수가 범주형일 경우 불순도의 척도로 엔트로피 지수를 이용한다.
③ 가장 널리 이용되는 의사결정나무 알고리즘이다.
④ 개별 입력변수 뿐만 아니라 입력 변수들의 선형 결합 중에서 최적의 분리를 구할 수 있다.

28. 다음 중 의사결정나무에 대한 설명으로 가장 옳지 않은 것은?
① 나무 구조에 의해서 모형이 표현되기 때문에 모형을 사용자가 쉽게 이해 가능하다.
② 두 개 이상의 변수가 결합하여 목표변수에 어떻게 영향을 주는지 쉽게 파악이 가능하다.
③ 선형성이나 정규성 또는 등분산성 등의 가정이 필요한 모수적 모형이다.
④ 연속형 변수를 비연속적인 값으로 취급하기 때문에 분리의 경계점 근방에서 예측 오류가 클 가능성이 있다.

29. 다음의 그림이 나타내는 뉴런의 활성화 함수는 무엇인가?

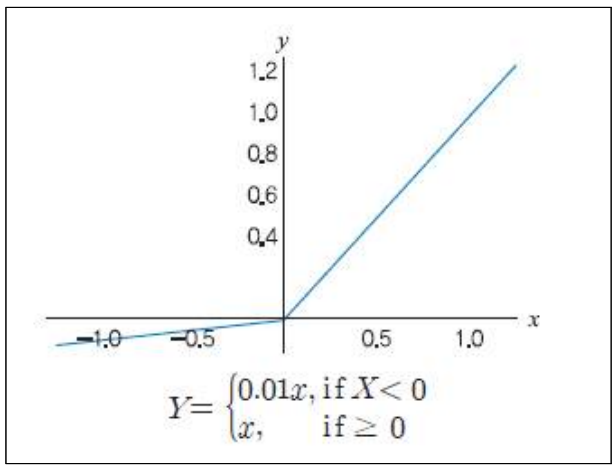


① 계단 함수 ② 시그모이드 함수
③ tanh 함수 ④ Leaky ReLU

30. 서포트 벡터 머신의 구성 요소 중에서 완벽한 분리가 불가능할 때 선형적으로 분류를 위해 허용된 오차를 위한 변수는 무엇인가?
① 결정 경계
② 슬랙 변수
③ 마진
④ 커널 트릭

## 4과목 빅데이터 결과 해석

31. 다음 중 알고리즘의 정확도를 판단하기 위한 AUC(Area Under ROC)의 수치 중 가장 좋은 모형은 무엇인가?
① 0.9 ② 0.7
③ 0.1 ④ 0.5

32. 다음 중 부트스트랩(Bootstrap)에 대한 설명으로 옳지 않은 것은?
① 무작위 복원추출 기법으로, 전체 데이터에서 중복을 허용하여 데이터 크기만큼 샘플을 추출하고 이를 학습 데이터로 한다.
② 주어진 자료에서 단순 랜덤 복원추출 방법으로 동일한 크기의 표본을 여러 개 생성하는 샘플링 방법이다.
③ 부트스트랩을 통해 100개의 샘플을 추출하더라도 샘플에 한 번도 선택되지 않는 원 데이터가 발생할 수 있는데 전체 샘플의 약 63.2%가 이에 해당한다.
④ 한 번도 포함되지 않는 샘플들은 평가(Test)에 사용한다.

33. 다음 중 취합(Aggregation) 방법론으로 가장 거리가 먼 것은?
① 다수결(Majority Voting)
② 배깅(Bagging)
③ 부스팅(Boosting)
④ 페이스팅(Pasting)

34. 교차검증 방법 중 모집단으로부터 조사의 대상이 되는 표본을 무작위로 추출 하는 기법은 무엇인가?

① Holdout Cross Validation
② LOOCV
③ k-Fold Cross Validation
④ Random Sampling

35. 다음 혼동 행렬(Confusion Matrix)에서 F1 스코어는 얼마인가?

| | | 예측값 | | 합계 |
|---|---|---|---|---|
| | | True | False | |
| 실제값 | True | 30 | 70 | 100 |
| | False | 20 | 80 | 100 |
| 합계 | | 50 | 150 | 200 |

① $\frac{2}{5}$ ② $\frac{3}{5}$
③ $\frac{1}{5}$ ④ $\frac{4}{5}$

36. 다음 중 경사 하강법의 단점을 개선해 주는 기법으로 옳지 않은 것은?
① Momentum ② AdaBoost
③ AdaGrad ④ Adam

37. 다음 중 데이터 시각화의 절차로 올바르게 연결된 것은?
① 구조화 단계→시각화 단계→시각표현 단계
② 시각화 단계→구조화 단계→시각표현 단계
③ 시각표현 단계→시각화 단계→구조화 단계
④ 시각표현 단계→구조화 단계→시각화 단계

38. 다음이 설명하는 데이터 시각화 기능은 무엇인가?

| - 데이터에 숨겨져 있는 관계와 패턴을 찾기 위한 시각적 분석 기능 |
|---|

| - 데이터의 유의미하고 흥미로운 요소를 이용자가 직접 탐색함 |
|---|

① 설명 기능
② 탐색 기능
③ 보안 기능
④ 표현 기능

39. 다음 중 빅데이터 시각화 도구로 가장 옳지 않은 것은 무엇인가?
① 태블로(Tableau)
② 인포그램(Infogram)
③ 데이터래퍼(Data Wrapper)
④ 하이브(Hive)

40. 다음 중 드롭아웃의 유형으로 옳지 않은 것은 무엇인가?
① 시간적 드롭아웃
② 간헐적 드롭아웃
③ 초기 드롭아웃
④ 공간적 드롭아웃